

TRANSFORMATION NUMÉRIQUE SI

IntraBot

Chatbot RAG pour la recherche
documentaire intranet

Fiche synthétique MVP • 2025-2026

Software Engineers

Managers

Business Analysts

Problématique & Irritants

“ *Comment transformer des sources de données multimodales pour faciliter la recherche documentaire via un chatbot ?* ”



Recherche inefficace

Navigation laborieuse dans des documents non structurés, sans moteur sémantique



Volume documentaire

Trop de fichiers (PDF, Word, intranet) rendant la consultation manuelle impossible



Perte de temps

Les collaborateurs perdent un temps précieux à chercher la bonne information

Fonctionnalités principales du MVP



Ingestion multimodale

PDF, Word, pages intranet — pipeline automatique de collecte et parsing



Recherche sémantique

RAG : embeddings vectoriels + retrieval des chunks les plus pertinents



Réponses sourcées

Le chatbot génère une réponse et cite explicitement les documents sources



Interface web

Interface de chat simple, épurée, accessible depuis le navigateur

Scénarios utilisateurs



Software Engineer

« Je cherche comment configurer le pipeline CI/CD »

✓ Résumé de la procédure + lien vers la page intranet correspondante



Business Analyst

« Quelles sont les règles métier pour valider un devis ? »

✓ Document de processus retrouvé + citation du paragraphe exact



Manager

« Donne-moi un résumé de la politique de télétravail »


✓ Synthèse de plusieurs docs RH avec sources indiquées

Utilisateur

Question

Réponse sourcée

Architecture logicielle — Pipeline RAG



Pipeline RAG — flux d'une requête

Question utilisateur

Embedding

Retrieval (top-k chunks)

Prompt augmenté

Réponse LLM + sources

Choix technologiques

Couche	Technologie	Justification
Frontend	React + Next.js	SSR, composants réutilisables, écosystème mature
Backend	Python + FastAPI	Langage IA/ML dominant, asynchrone, typage strict
Orchestration	LangChain / LlamaIndex	Pipeline RAG haut niveau, multi-LLM, actif
LLM	Gemini API (Google)	Contexte étendu, coût inférieur, API simple
Base vectorielle	ChromaDB → Qdrant	Dev local (Chroma) / prod scalable (Qdrant OSS)
Base relationnelle	PostgreSQL	Standard ACID, logs, sessions, métadonnées
Conteneurisation	Docker + Compose	Reproductibilité, déploiement simplifié, standard DevOps

Répartition des tâches

T1 Ingestion & Parsing

- Récupérer PDF, Word, pages web
- Découper en chunks (PyMuPDF / python-docx)
- Nettoyer les données

T2 Pipeline RAG & Vectoriel

- Générer les embeddings
- Configurer ChromaDB
- Implémenter la recherche sémantique

T3 LLM & Prompt Engineering

- Connecter l'API Gemini
- Écrire les prompts RAG
- Gérer les cas sans document pertinent

T4 Backend FastAPI

- Créer les endpoints (POST /chat)
- Lier frontend, RAG et LLM
- Gérer l'historique de conversation

T5 Frontend & Intégration

- Interface de chat propre
- Connexion au backend
- Affichage des réponses + sources

Un chatbot documentaire RAG, fiable et sourcé

- 4 fonctionnalités MVP ciblées sur l'essentiel

- 3 personae couverts : Dev, BA, Manager

- Architecture RAG en 3 couches (Frontend / Backend / Data)

- Stack Python + Gemini + ChromaDB/Qdrant — open & scalable

- 5 tâches réparties pour le sprint suivant